МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
**«МИРЭА – Российский технологический университет»**

**РТУ МИРЭА**

---

**Институт информационных технологий (ИИТ)**
**Кафедра корпоративных информационных систем (КИС)**

# ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ

по дисциплине «Управление информационно-технологической инфраструктурой и архитектурой»

Студенты группы *ИКМО-03-25 Фомичев Р.А.* _____
(подпись)

Преподаватель *Назаров А.Н.*

_____
(подпись)

Отчет представлен «___»_____2026 г.

Москва 2026 г.

Цель практической работы: разработать программное решение с использованием облачных технологий, а также выполнить вычисление через Hadoop.

В ходе практической работы было проведено исследование цен и скидок на товары интернет-торговли на примере ассортимента Sephora. В условиях активного развития онлайн-ритейла пользователи всё чаще сталкиваются с широким разбросом цен, различными скидочными предложениями и большим количеством брендов в рамках одной торговой площадки, что делает актуальным анализ таких данных с точки зрения конечного покупателя. Это и обусловило необходимость изучения данной области с применением технологий распределённой обработки данных.

**В рамках практической работы необходимо:**

- Изучить архитектуру проекта анализа цен и скидок товаров Sephora.
- Ознакомиться с принципами работы Hadoop HDFS и Apache Spark.
- Развернуть проект с использованием Docker.
- Запустить систему анализа данных.
- Выполнить обработку датасета и построение аналитических результатов.
- Описать полученные результаты.

Проект представляет собой распределённую систему анализа данных о ценах и скидках товаров интернет-магазина Sephora.

**Система предназначена для:**

- загрузки и хранения CSV-данных в распределённой файловой системе HDFS,
- выполнения аналитической обработки данных о товарах,
- сохранения результатов анализа в виде агрегированных таблиц,
- построения визуализаций по итогам обработки данных.

В качестве набора данных используется файл с информацией о товарах Sephora, включающий сведения о названии товара, бренде, категориях, цене, скидочной цене, рейтинге, количестве отзывов и других характеристиках.

**В проекте применяются следующие технологии:**

Apache Hadoop – используется для организации распределённой файловой системы HDFS.

Apache Spark – применяется для распределённой обработки данных.

Python – язык программирования, на котором реализована логика анализа и визуализации данных.

Docker и Docker Compose – используются для контейнеризации и управления сервисами.

Pandas и Matplotlib – используются для построения диаграмм и итоговой визуализации результатов.

**Архитектура проекта включает следующие компоненты:**

– Spark-контейнер для запуска аналитического PySpark-скрипта.

– HDFS (NameNode и DataNode).

– YARN (ResourceManager и NodeManager).

– HistoryServer для хранения истории выполнения заданий.

– Контейнеры Docker для каждого сервиса.

**Принцип работы системы:**

– Пользователь загружает исходный CSV-файл с данными о товарах в проект.

– Файл помещается в распределённую файловую систему HDFS.

– Spark выполняет распределённую обработку данных, размещённых в HDFS.

– В результате вычисляются агрегированные показатели по категориям, брендам, ценам и скидкам.

– Полученные результаты сохраняются в HDFS и затем используются для построения диаграмм.

**В ходе выполнения практической работы были выполнены следующие действия:**

– Подготовлена структура проекта и изучена конфигурация docker-compose.yml.

– Установлены и настроены Docker и Docker Compose.

– Развернут контейнеризированный стенд Hadoop и Spark.

– Выполнен запуск системы командой: docker compose up -d

– Проверена корректность запуска контейнеров и доступность HDFS.

– Исходный датасет Sephora Products загружен в HDFS.

– Запущен PySpark-скрипт анализа данных.

– Выполнена очистка набора данных и расчёт производных показателей, включая итоговую цену, абсолютную и относительную скидку, а также метрику выгодности товара.

– Получены агрегированные результаты по категориям и брендам товаров.

– Построены визуализации, отражающие средние цены, средние скидки, распределение цен, соотношение цены и рейтинга, а также наиболее выгодные товарные позиции.

На рисунке 1 изображен выбранный датасет.

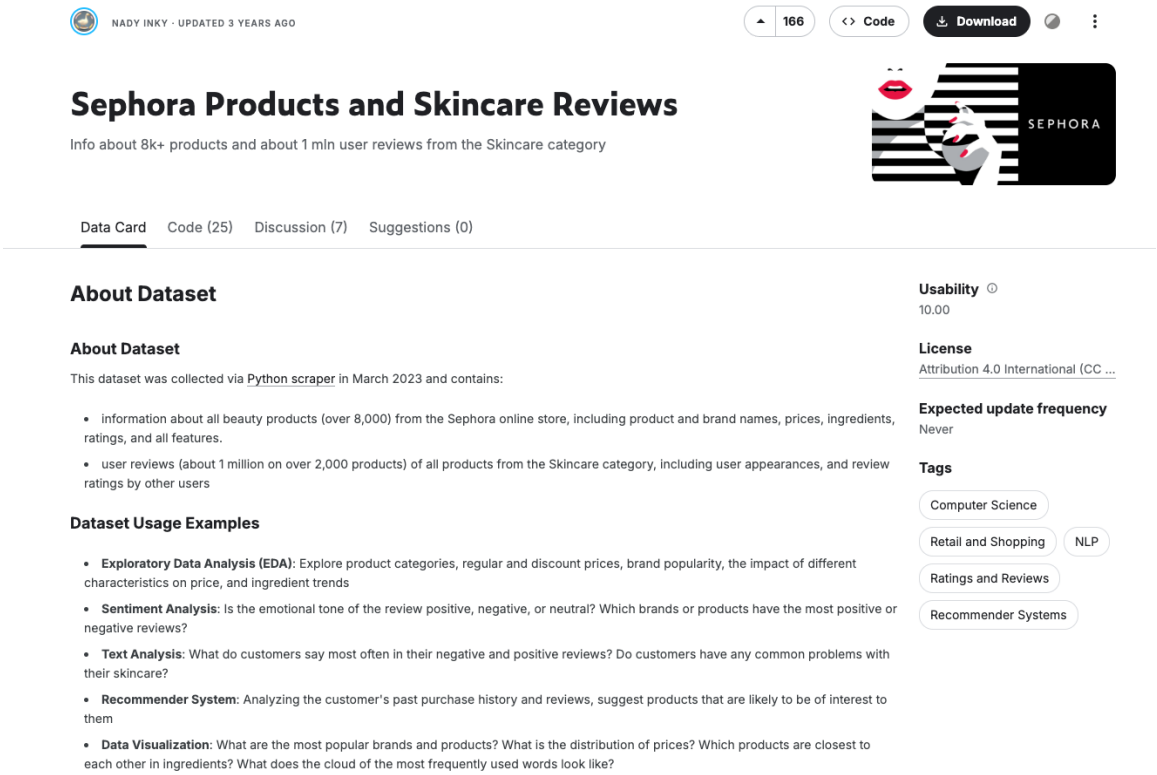



Рисунок 1 – Выбранный датасет

На рисунке 2 изображена архитектура проекта.

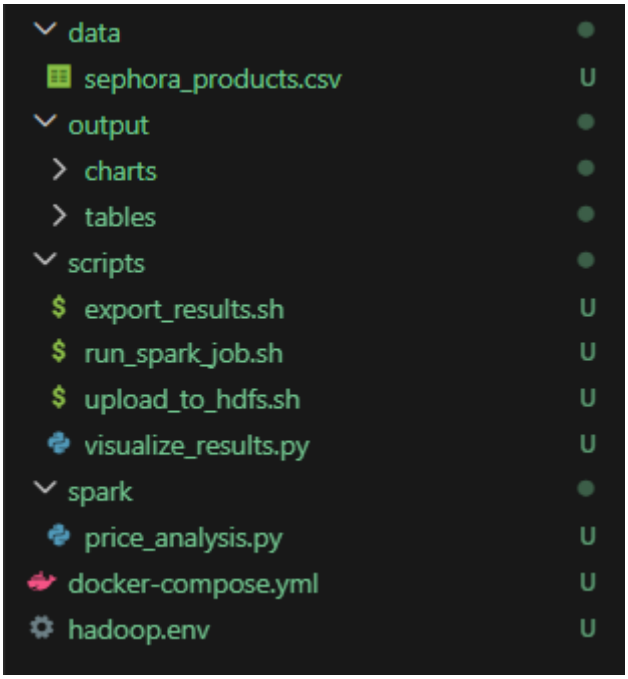



Рисунок 2 – Архитектура проекта

На рисунке 3 изображены запущенные контейнеры для работы.

– NameNode управляет HDFS и хранит метаданные.

– DataNode хранит реальные файлы и результаты обработки.

– ResourceManager управляет ресурсами и задачами в YARN.

– NodeManager исполняет вычислительные процессы на узле.

– HistoryServer хранит историю выполнения заданий.

– Spark запускает аналитический скрипт и выполняет обработку данных.

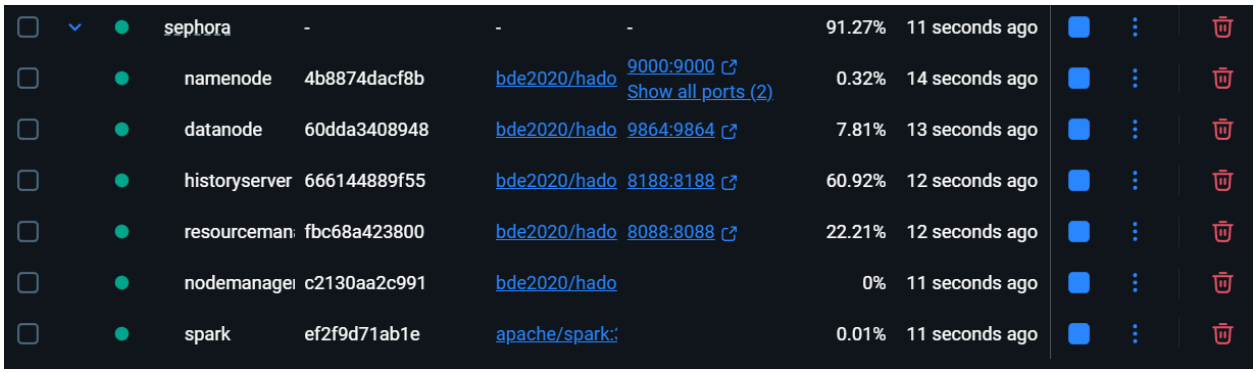



Рисунок 3 – Запущенные контейнеры Docker

Для загрузки датасета на hdfs был создан скрипт, изображенный на рисунке 4.

scripts > $ upload_to_hdfs.sh

```
#!/bin/bash
set -e
HDFS_DIR="/user/project"
LOCAL_FILE="/data/sephora_products.csv"

docker exec -it namenode hdfs dfs -mkdir -p ${HDFS_DIR}
docker exec -it namenode hdfs dfs -put -f ${LOCAL_FILE} ${HDFS_DIR}/sephora_products.csv
docker exec -it namenode hdfs dfs -ls ${HDFS_DIR}

```

Рисунок 4 – Скрипт для загрузки датасета на сервер

Далее нужно очистить данные, нормализовать и в общем подготовить их для дальнейшего анализа. С этим как раз таки помогает Spark. Часть скрипта изображена на рисунке 5.

spark > price_analysis.py > ...

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, when, avg, count, sum as spark_sum, round as spark_round

spark = SparkSession.builder.appName("Sephora Price Analysis").getOrCreate()

input_path = "hdfs://namenode:9000/user/project/sephora_products.csv"
output_path = "hdfs://namenode:9000/user/project/output"

df = spark.read.csv(input_path, header=True, inferSchema=True)

selected = df.select(
    "product_id", "product_name", "brand_name", "primary_category", "price_usd",
    "sale_price_usd", "rating", "reviews", "loves_count", "out_of_stock"
).dropna(subset=["product_id", "product_name", "brand_name", "primary_category", "price_usd"])
```

Рисунок 5 – Часть скрипта для Spark.

Далее надо их выгрузить, для этого был написан скрипт для удобной выгрузки с hdfs сервера (Рисунок 6), чтобы результаты, сохранённые Spark в HDFS, можно было использовать локально для построения графиков и подготовки отчёта.

scripts > $ export_results.sh

```
#!/bin/bash
set -e
mkdir -p ./output/tables

docker exec namenode hdfs dfs -get -f /user/project/output/category_summary /tmp/category_summary
docker exec namenode hdfs dfs -get -f /user/project/output/brand_summary /tmp/brand_summary
docker exec namenode hdfs dfs -get -f /user/project/output/top_discounted_products /tmp/top_discounted_products
docker exec namenode hdfs dfs -get -f /user/project/output/top_value_products /tmp/top_value_products
docker cp namenode:/tmp/category_summary ./output/tables/
docker cp namenode:/tmp/brand_summary ./output/tables/
docker cp namenode:/tmp/top_discounted_products ./output/tables/
docker cp namenode:/tmp/top_value_products ./output/tables/

```

Рисунок 6 – Скрипт для выгрузки полученных данных

Остается только визуализировать. В этом поможет скрипт, использующий matplotlib и pandas, на языке Python (Рисунок 7). Результат вычислений представлен на рисунках 8-16.

scripts > visualize_results.py > ...

```python
import os
import glob
import pandas as pd
import matplotlib.pyplot as plt

BASE_DIR = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
DATA_PATH = os.path.join(BASE_DIR, "data", "sephora_products.csv")
CHARTS_DIR = os.path.join(BASE_DIR, "output", "charts")
os.makedirs(CHARTS_DIR, exist_ok=True)

df = pd.read_csv(DATA_PATH)
df["final_price"] = df["sale_price_usd"].fillna(df["price_usd"])
df["discount_abs"] = (df["price_usd"] - df["final_price"]).clip(lower=0)
df["discount_percent"] = (df["discount_abs"] / df["price_usd"] * 100).fillna(0)
```

Рисунок 7 – Часть скрипта для визуализации данных

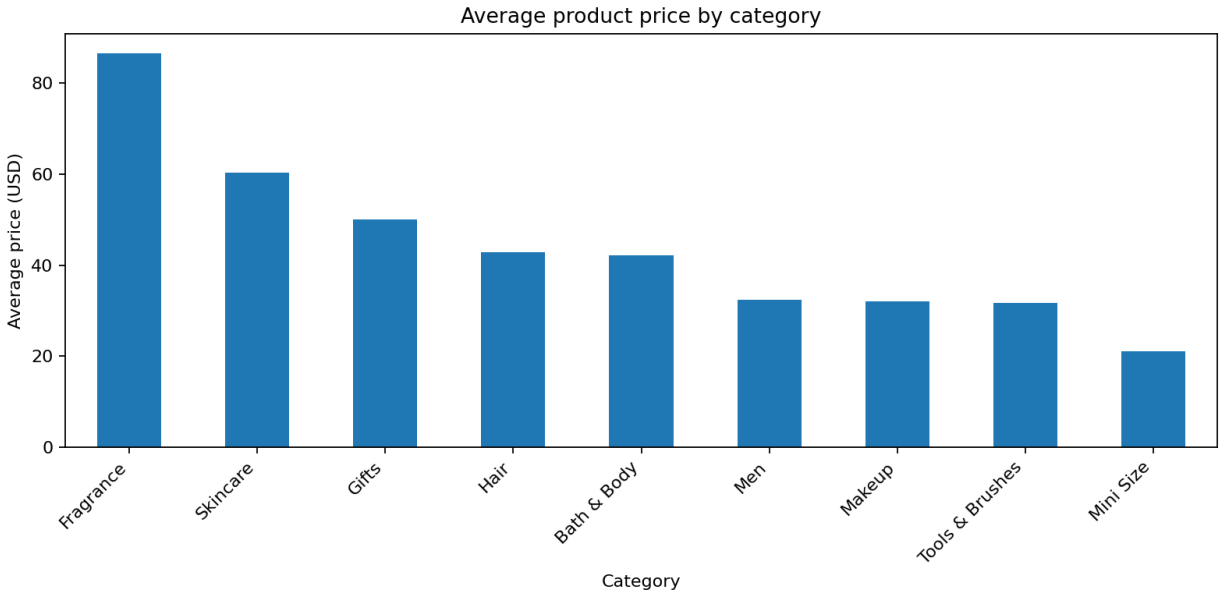



Рисунок 8 – Средняя цена по категориям

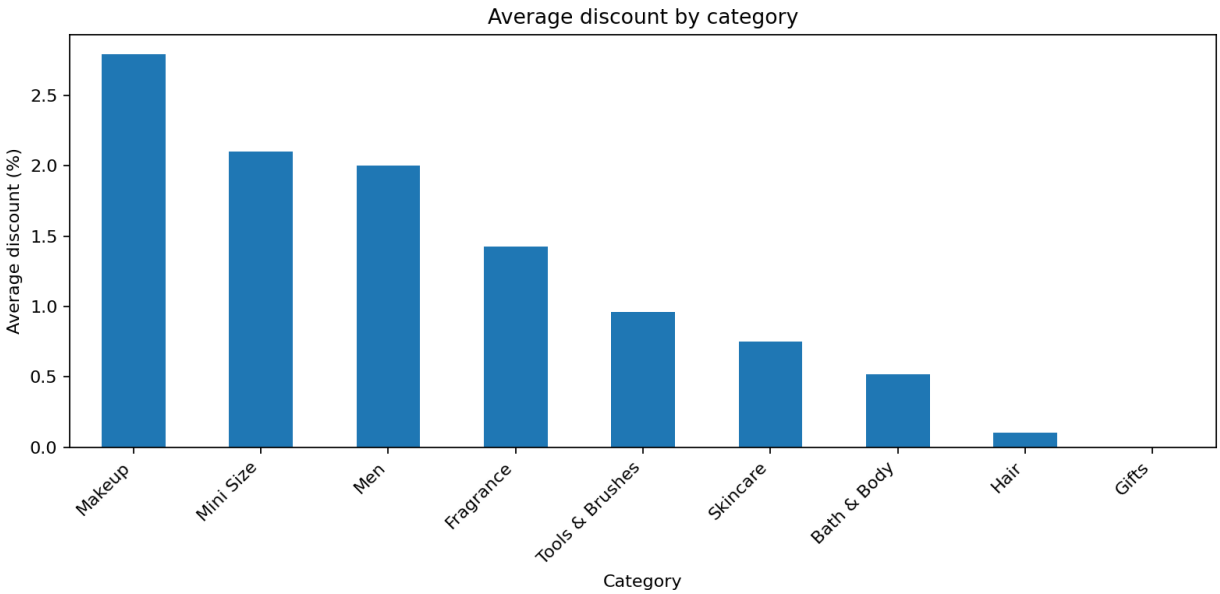



Рисунок 9 – Средняя скидка по категориям

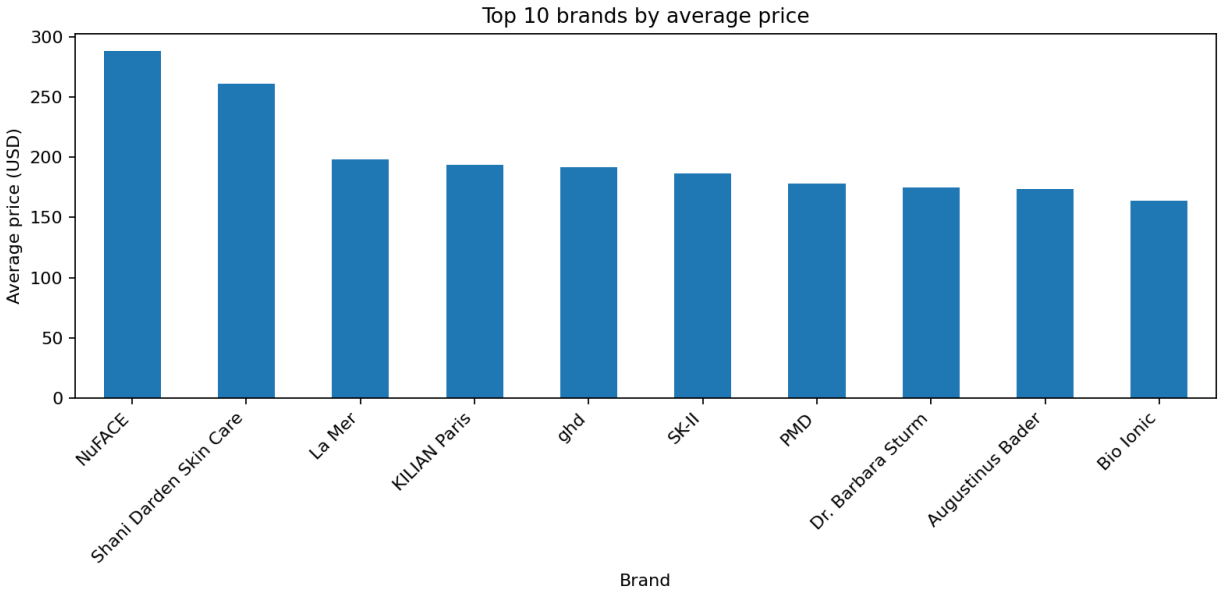



Рисунок 10 – Топ-10 брендов по средней цене

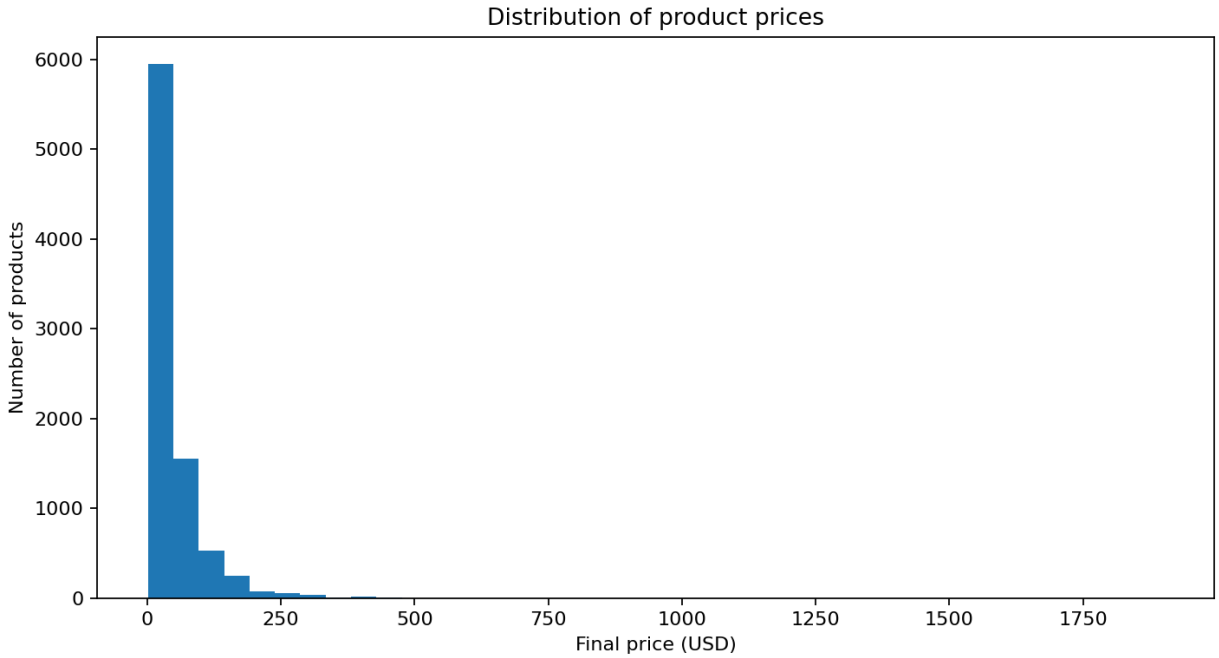



Рисунок 11 – Полное распределение цен

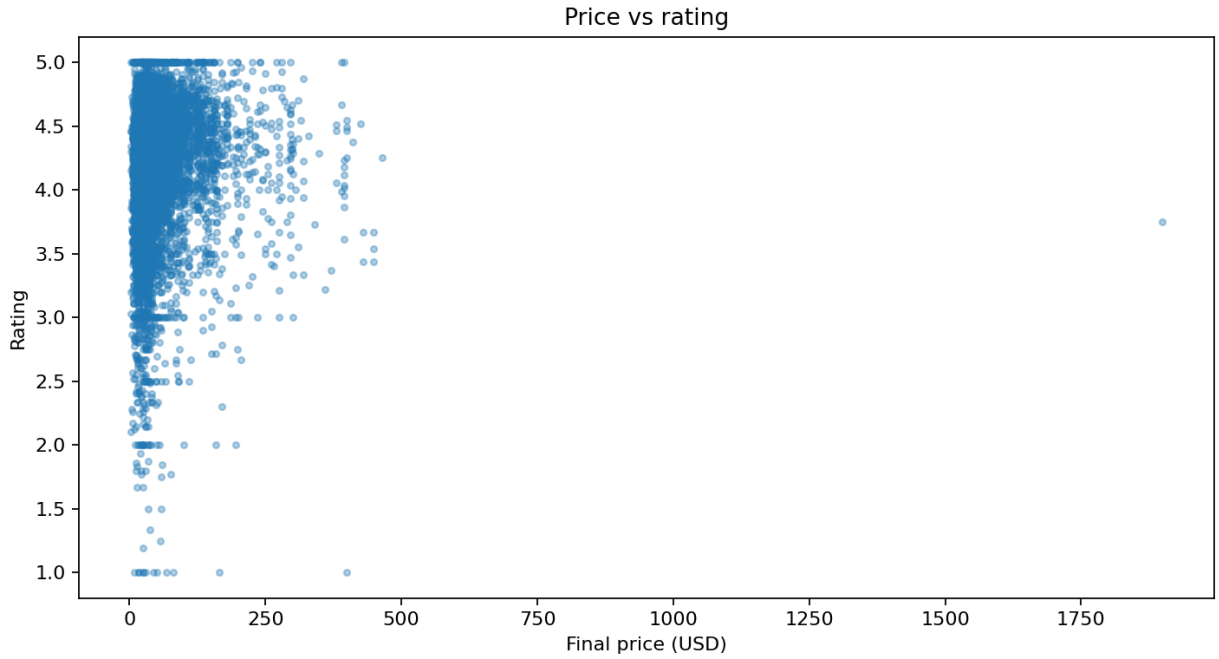



Рисунок 12 – Цена и рейтинг

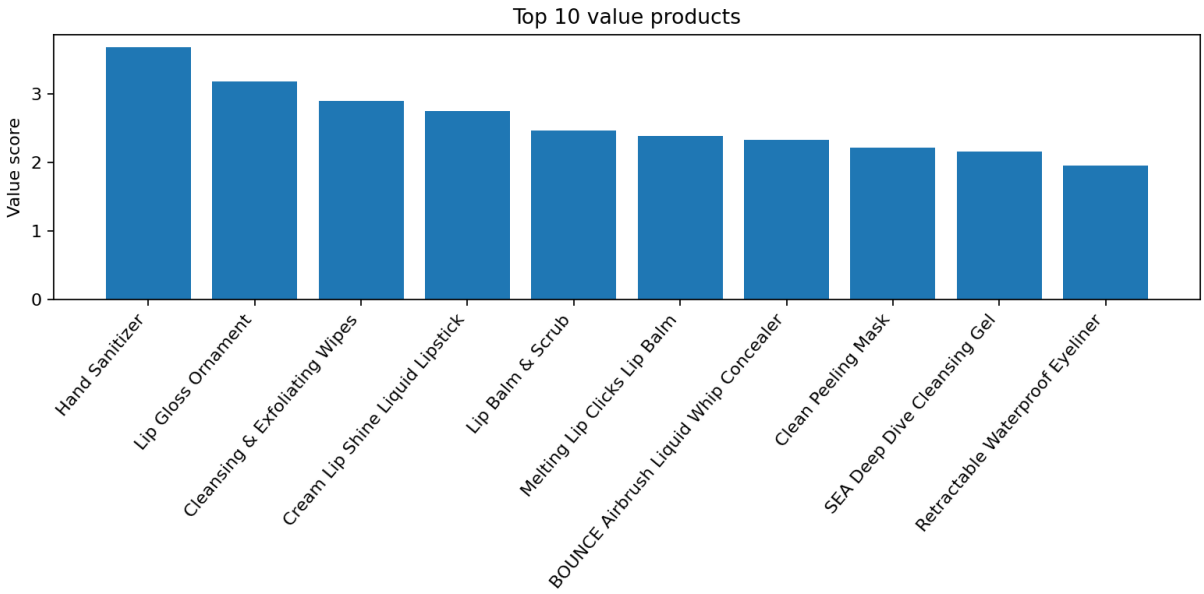



Рисунок 13 – Топ-10 выгодных товаров

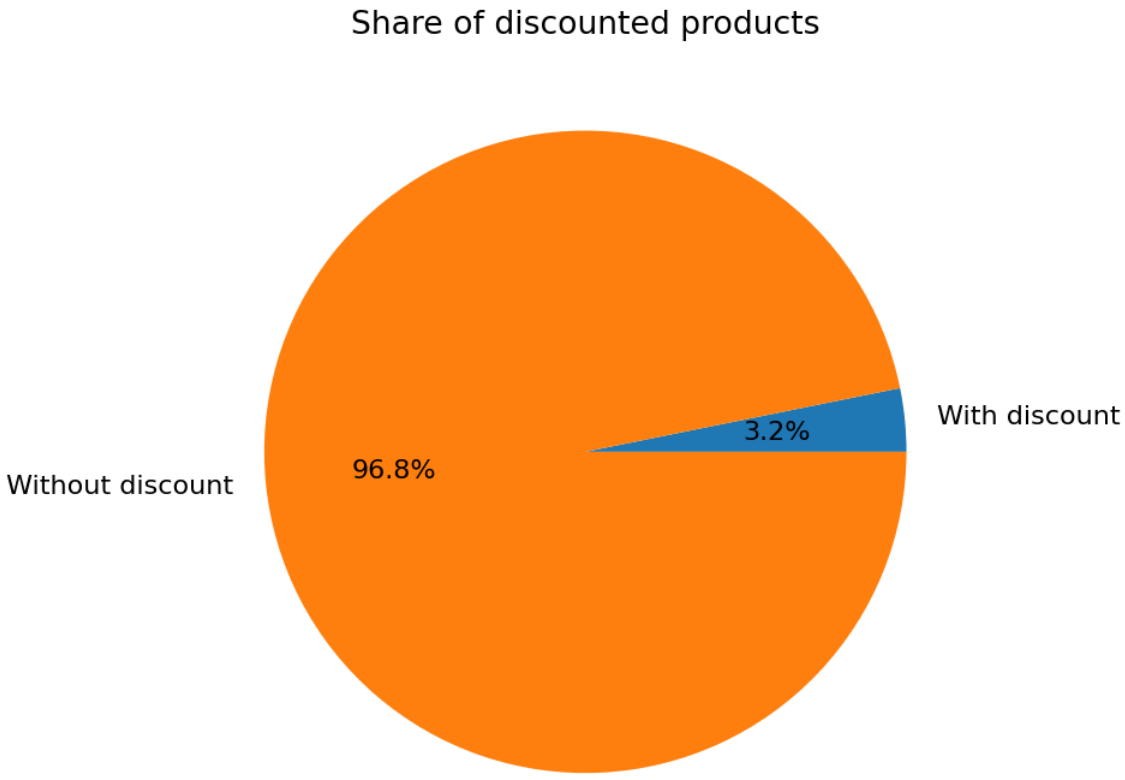



Рисунок 14 – Количество товаров со скидкой и без

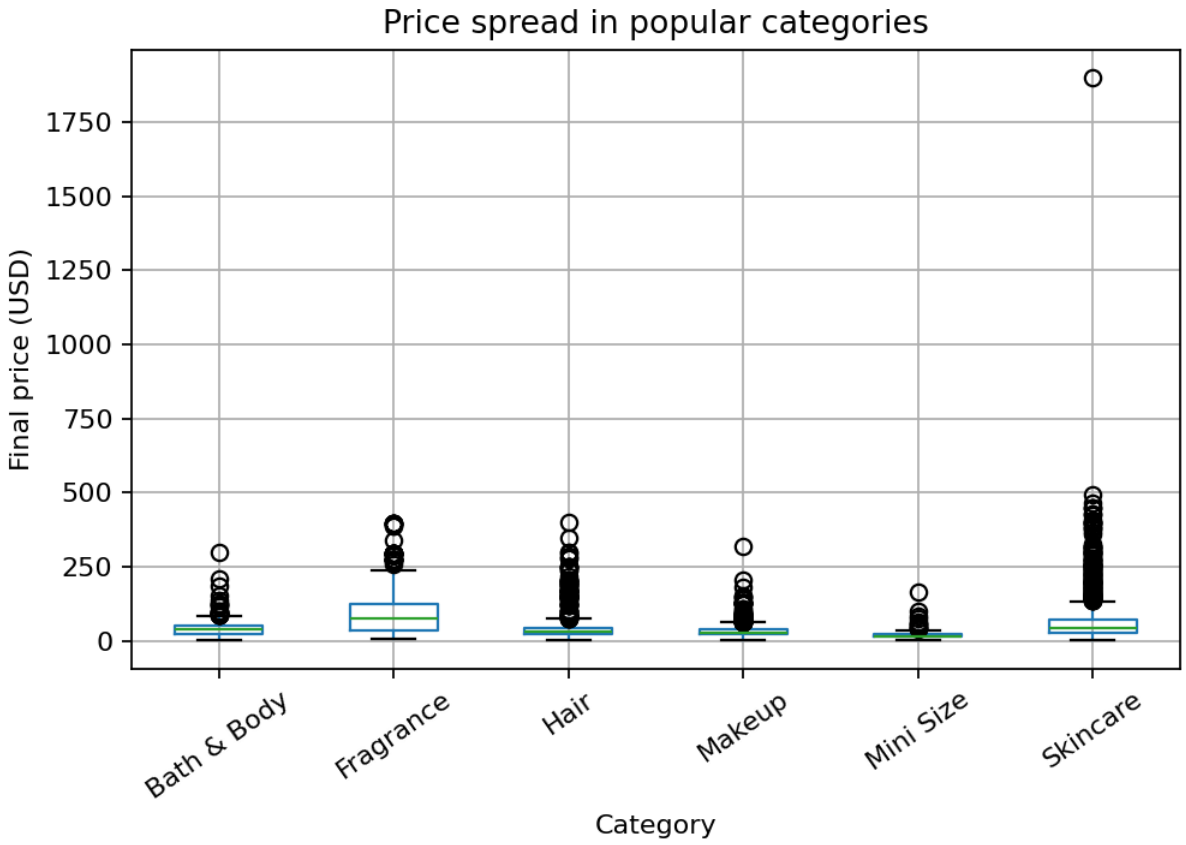



Рисунок 15 – Разброс цен в популярных категориях

| | metric | value |
|---|---|---|
| 2 | Total products | 8494 |
| 3 | Total categories | 9 |
| 4 | Total brands | 304 |
| 5 | Average product price | 51.23 |
| 6 | Average discount percent | 1.37 |
| 7 | Average rating | 4.19 |
| 8 | Discounted products share | 3.18 |
| 9 | Most expensive category | Fragrance |
| 10 | Highest discount category | Makeup |

Рисунок 16 – Итоговый отчет

**Заключение**

В ходе практической работы был развернут контейнеризированный стенд для распределённой обработки данных, включающий Hadoop HDFS, YARN и Apache Spark. Исходный датасет Sephora Products был загружен в HDFS, после чего с помощью PySpark была выполнена очистка данных, вычисление производных признаков скидки и агрегированный анализ по категориям и брендам. Результаты обработки были сохранены в распределённом хранилище в форматах CSV и Parquet.